

Journal Name

Crossmark

PAPER

RECEIVED
dd Month yyyy

REVISED
dd Month yyyy

Predicción de la Transición de Intensidad en Incendios Forestales del Biobío: Un Enfoque de Machine Learning con Variables Climáticas Rezagadas

Gerardo Galán¹ and Mabel Herrera P.²

¹Magíster en Data Science, Uinversidad de las Américas, Concepción, Chile

²Magíster en Data Science, Uinversidad de las Américas, Concepción, Chile

*Author to whom any correspondence should be addressed.

E-mail: ggalanc@gmail.com

Keywords: Incendios forestales, potencia radiativa de fuego, random forest, gestión de desastres, climatología sinóptica.

Abstract

La intensificación de los incendios forestales en la región del Biobío, Chile, ha incrementado la frecuencia de eventos de alta intensidad energética, asociados a un comportamiento extremo del fuego y a elevados riesgos para brigadas, comunidades y ecosistemas. Más allá de la ignición inicial, uno de los principales desafíos para la gestión del riesgo es anticipar qué incendios evolucionarán hacia escenarios críticos caracterizados por valores máximos elevados de Potencia Radiativa del Fuego (Fire Radiative Power, FRP). En este estudio se desarrolla y evalúa un modelo de aprendizaje automático basado en Random Forest para predecir la ocurrencia de incendios forestales severos, definidos como aquellos eventos cuya FRP máxima es mayor o igual a 100 MW.

El enfoque propuesto integra variables meteorológicas actuales y rezagadas de temperatura, humedad relativa, velocidad del viento y precipitación, junto con información energética inicial del incendio, con el fin de capturar el efecto acumulativo de las condiciones climáticas previas sobre el estado del combustible vegetal. Para ello, se reconstruyeron eventos de incendio únicos a partir de detecciones satelitales mediante un proceso de agrupación espacio-temporal, y se generaron variables climáticas con rezagos de hasta tres días.

Los resultados muestran que el modelo Random Forest es capaz de discriminar eventos severos con un desempeño ajustable según el objetivo operativo, evidenciando un compromiso explícito entre sensibilidad y precisión. El análisis de importancia de variables revela que la intensidad extrema del fuego está dominada por condiciones térmicas persistentes y baja humedad relativa acumulada, mientras que el FRP inicial actúa como un ancla energética que condiciona la escalabilidad del incendio. En conjunto, los hallazgos confirman que los incendios de alta intensidad en el Biobío responden a procesos acumulativos más que a condiciones meteorológicas instantáneas aisladas, y destacan el potencial de integrar memoria climática y aprendizaje automático no lineal para el desarrollo de sistemas de alerta temprana orientados a la gestión del riesgo de incendios forestales.

1 INTRODUCCIÓN

La ocurrencia de incendios forestales en la zona centro-sur de Chile se ha intensificado de manera significativa durante la última década, como resultado combinado de la megasequía prolongada, el aumento de temperaturas extremas y la expansión de plantaciones forestales altamente combustibles. En este contexto, la región del Biobío se ha consolidado como un hotspot de incendios forestales, concentrando un número relevante de eventos con alto potencial destructivo y elevados costos sociales, ambientales y económicos.

Más allá de la ignición inicial —frecuentemente asociada a causas antrópicas—, uno de los principales desafíos para la gestión del riesgo es anticipar el comportamiento posterior del fuego, en particular la ocurrencia de incendios de alta intensidad energética, caracterizados por una

liberación extremadamente rápida de energía térmica. Un indicador ampliamente utilizado para cuantificar esta intensidad es la Potencia Radiativa del Fuego (Fire Radiative Power, FRP), la cual representa la tasa instantánea de energía radiativa emitida por el incendio y se encuentra directamente relacionada con la velocidad de consumo de biomasa.

Diversos estudios han identificado que eventos con valores de FRP máximo iguales o superiores a 100 MW se asocian a incendios de comportamiento extremo, mayor dificultad de control, generación de focos secundarios y condiciones altamente peligrosas para brigadas y población expuesta. Por esta razón, el umbral de 100 MW es frecuentemente utilizado en la literatura y en contextos operativos como un punto de inflexión entre incendios de intensidad moderada y eventos severos.

A pesar de los avances en sistemas de monitoreo satelital y modelamiento predictivo, gran parte de los enfoques existentes se centra en condiciones meteorológicas instantáneas, sin considerar adecuadamente el efecto acumulativo de las condiciones climáticas previas sobre el estado hídrico del combustible vegetal. Sin embargo, existe evidencia creciente de que la intensidad alcanzada por un incendio no depende únicamente del clima del momento, sino también de una “memoria climática” asociada a la temperatura, humedad, viento y precipitaciones registradas en los días anteriores al evento.

En este contexto, surge la necesidad de desarrollar modelos predictivos capaces de identificar, de forma anticipada, aquellos eventos de incendio que tienen alta probabilidad de alcanzar niveles críticos de intensidad ($FRP \geq 100MW$), incorporando tanto variables meteorológicas actuales como rezagadas.

2 PLANTEAMIENTO DEL PROBLEMA

La región del Biobío enfrenta de manera recurrente incendios forestales que, en un subconjunto de casos, evolucionan hacia eventos de alta intensidad energética, caracterizados por valores máximos de FRP iguales o superiores a 100 MW. Estos eventos representan un desafío significativo para los sistemas de prevención y combate, debido a su rápida evolución y al elevado riesgo que implican para brigadas, comunidades cercanas y ecosistemas.

Sin embargo, la identificación anticipada de estos incendios severos continúa siendo compleja, dado el carácter no lineal del fenómeno y la interacción entre múltiples variables climáticas. La mayoría de los sistemas de alerta temprana se basa en condiciones meteorológicas del momento, lo que limita su capacidad para capturar el efecto acumulativo de episodios previos de altas temperaturas, baja humedad relativa y escasas precipitaciones.

En consecuencia, persiste una brecha en el desarrollo de modelos predictivos que integren explícitamente variables meteorológicas rezagadas y que permitan discriminar, desde las etapas iniciales, aquellos eventos con alta probabilidad de alcanzar niveles críticos de intensidad.

El problema central que guía este estudio se formula de la siguiente manera:

¿Es posible predecir la ocurrencia de eventos de incendio forestal que alcancen una Potencia Radiativa del Fuego máxima igual o superior a 100 MW en la región del Biobío, a partir de variables meteorológicas actuales y rezagadas, utilizando técnicas de aprendizaje automático?

3 OBJETIVOS

3.1 Objetivo general

Desarrollar y evaluar un modelo de aprendizaje automático capaz de predecir la ocurrencia de eventos de incendio forestal de alta intensidad energética ($FRP_{máximo} \geq 100MW$) en la región del Biobío, a partir de variables meteorológicas actuales y rezagadas.

3.2 Objetivos específicos

- Reconstruir eventos de incendio únicos mediante un proceso de agrupación espacio-temporal aplicado a detecciones satelitales individuales.
- Generar variables climáticas rezagadas de temperatura, humedad relativa, velocidad del viento y precipitaciones, con el fin de capturar el efecto acumulativo de las condiciones previas al evento.
- Entrenar un modelo de clasificación basado en Random Forest para discriminar entre eventos severos ($FRP \geq 100MW$) y no severos.
- Evaluar el desempeño del modelo utilizando métricas adecuadas para conjuntos de datos desbalanceados, priorizando la detección de eventos críticos.

- Analizar la importancia relativa de las variables predictoras para identificar los principales factores climáticos asociados a incendios de alta intensidad energética.

4 HIPÓTESIS DE INVESTIGACIÓN

La hipótesis central de este estudio plantea que los eventos de incendio forestal que alcanzan una Potencia Radiativa del Fuego máxima igual o superior a 100 MW en la región del Biobío pueden ser predichos a partir de la combinación de condiciones meteorológicas instantáneas y rezagadas.

En particular, se postula que las variables climáticas rezagadas —especialmente la temperatura y la humedad relativa de los días previos al inicio del evento— desempeñan un rol determinante en la ocurrencia de incendios de alta intensidad energética, al reflejar el estado acumulado de desecación y estrés térmico del combustible vegetal.

5 VARIABLE RESPUESTA Y DISEÑO EXPERIMENTAL

5.1 Definición de la variable respuesta

La variable respuesta de este estudio se definió con el objetivo de identificar eventos de incendio forestal que alcanzan niveles críticos de intensidad energética. Para ello, se utilizó la Potencia Radiativa del Fuego máxima (FRP máxima) registrada durante cada evento de incendio reconstruido.

A partir de este indicador continuo, se construyó una variable binaria de clasificación que distingue entre incendios severos y no severos, según el siguiente criterio:

- **Clase 1 (Incendio severo):** eventos cuya FRP máxima es mayor o igual a 100 MW.
- **Clase 0 (Incendio no severo):** eventos cuya FRP máxima es menor a 100 MW.

El umbral de 100 MW se seleccionó debido a su uso recurrente en la literatura especializada y en contextos operativos como referencia para incendios de comportamiento extremo, asociados a una elevada liberación de energía, rápida propagación y mayores dificultades de control. De este modo, la variable respuesta se alinea con un criterio de relevancia práctica para la gestión del riesgo, más que con un cambio relativo de intensidad durante el evento.

5.2 Justificación del enfoque de clasificación

La formulación del problema como una tarea de clasificación binaria responde a la necesidad de anticipar, desde las etapas iniciales del incendio, la probabilidad de que un evento evolucione hacia un escenario de alta intensidad energética. Este enfoque permite traducir la salida del modelo en una señal de alerta temprana, potencialmente útil para la toma de decisiones operativas.

A diferencia de enfoques basados en la predicción de incrementos relativos de intensidad, la clasificación de eventos severos en función de un umbral absoluto de FRP prioriza la identificación de aquellos incendios con mayor impacto potencial, independientemente de su trayectoria inicial.

5.3 Diseño experimental y partición de los datos

El conjunto de datos consolidado, compuesto por eventos de incendio reconstruidos mediante un proceso de agrupación espacio-temporal, fue dividido en subconjuntos de entrenamiento y prueba. Se utilizó una partición estratificada, con un 80 % de los eventos destinados al entrenamiento del modelo y un 20 % reservado para la evaluación, preservando la proporción relativa entre eventos severos y no severos.

Dado que los incendios con $FRP_{máxima} \geq 100MW$ representan un subconjunto minoritario del total de eventos, el problema presenta un desbalance de clases. Para mitigar este efecto y evitar que el modelo privilegie la clase mayoritaria, se incorporaron ponderaciones inversamente proporcionales a la frecuencia de cada clase durante el entrenamiento.

5.4 Consideraciones metodológicas

El desempeño del modelo se evaluó utilizando métricas apropiadas para conjuntos de datos desbalanceados, priorizando la capacidad de detección de eventos severos. En este contexto, la sensibilidad (recall) de la clase severa se consideró una métrica crítica, dado que la omisión de incendios de alta intensidad implica un riesgo significativo desde el punto de vista operativo.

Adicionalmente, se analizó el compromiso entre sensibilidad y precisión mediante el ajuste del umbral de decisión del clasificador, con el fin de reducir la tasa de falsas alarmas sin comprometer excesivamente la detección de eventos críticos. Este enfoque permite evaluar distintos escenarios de uso del modelo, en función de los requerimientos de gestión y disponibilidad de recursos.

6 PREPROCESAMIENTO DE DATOS Y FLUJO METODOLÓGICO

6.1 Fuentes de datos

El conjunto de datos utilizado en este estudio se construyó a partir de la integración de dos fuentes principales: (i) registros de focos de incendio detectados por sensores satelitales, que incluyen información espacial (latitud y longitud), temporal y de Potencia Radiativa del Fuego (FRP); y (ii) variables meteorológicas asociadas a la región del Biobío, correspondientes a temperatura, humedad relativa, velocidad del viento y precipitaciones.

Ambos conjuntos de datos fueron cargados y procesados utilizando el lenguaje Python, empleando bibliotecas estándar para análisis de datos y cálculo geoespacial.

6.2 Normalización temporal y depuración inicial

Dado que los datos satelitales crudos presentan detecciones individuales ("píxeles") que no representan la continuidad de un incendio, se diseñó un algoritmo de agrupación espacio-temporal para reconstruir "eventos de incendio" únicos. Este flujo de procesamiento, crítico para la correcta evaluación de la transición de intensidad, consistió en tres etapas:

6.2.1 Binning Espacial Se aplicó un redondeo de coordenadas a dos decimales (≈ 1.1 km de precisión) para agrupar detecciones adyacentes pertenecientes a un mismo foco.

6.2.2 Segmentación Temporal (Sessionizing) Se ordenaron cronológicamente las detecciones por ubicación. Se definió el inicio de un nuevo evento cuando la diferencia temporal entre dos detecciones consecutivas en la misma ubicación superaba las 24 horas ($time_diff > 24h$). Esto permitió diferenciar rebrotos o nuevos incendios en una misma zona.

6.2.3 Generación de Variables de Rezago (Lags) Para capturar la inercia térmica y la desecación acumulada, se generaron variables históricas (t_{-1}, t_{-2}, t_{-3} días) para cada comuna y fecha de inicio del evento, abarcando temperatura media, humedad relativa, velocidad del viento y precipitación acumulada.

Tras este proceso, el dataset original de detecciones puntuales fue reducido a **2.759** eventos consolidados.

6.3 Construcción del dataset final

Como resultado del flujo de procesamiento descrito, el conjunto inicial de detecciones puntuales fue transformado en un dataset estructurado a nivel de eventos de incendio, en el cual cada registro representa un evento único caracterizado por su intensidad máxima (FRP máxima), variables climáticas actuales y rezagadas, y su clasificación como incendio severo o no severo según el umbral definido.

Este dataset final constituye la base para el modelamiento predictivo y el análisis de resultados presentados en las secciones siguientes.

7 MODELAMIENTO PREDICTIVO

7.1 Selección del algoritmo

Para el desarrollo del modelo predictivo se empleó el algoritmo Random Forest Classifier, debido a su capacidad para modelar relaciones no lineales, capturar interacciones complejas entre variables climáticas y manejar datos ruidosos sin requerir supuestos paramétricos estrictos. Estas características lo hacen particularmente adecuado para la predicción de incendios forestales de alta intensidad energética, un fenómeno influenciado por múltiples factores que interactúan de forma no lineal.

Asimismo, Random Forest permite estimar la importancia relativa de las variables predictoras, facilitando la interpretación física de los resultados y su vinculación con procesos ambientales subyacentes.

7.2 Configuración del modelo y manejo del desbalance de clases

El modelo fue entrenado sobre el conjunto de entrenamiento definido previamente, incorporando ponderaciones inversamente proporcionales a la frecuencia de las clases (class weighting), con el objetivo de mitigar el desbalance existente entre incendios severos ($FRP_{máximo} \geq 100MW$) y no severos.

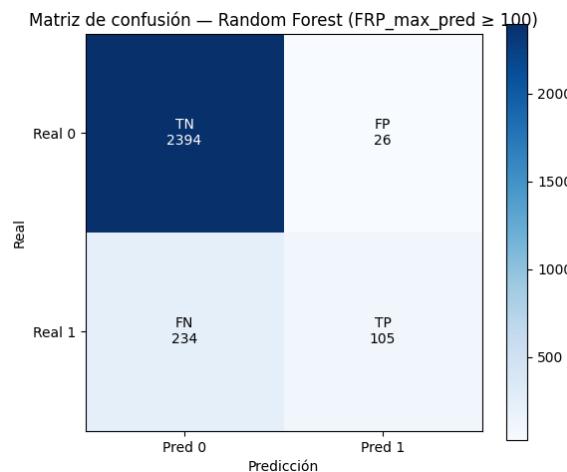


Figure 1. Matriz de confusión del modelo Random Forest con balanceo de clases.

Este ajuste resulta fundamental para evitar que el modelo privilegie la clase mayoritaria y para aumentar la sensibilidad en la detección de eventos críticos, cuya omisión representa un riesgo significativo desde el punto de vista operativo.

7.3 Desempeño del modelo

El modelo Random Forest alcanzó un desempeño consistente en la detección de incendios severos, logrando una precisión de 0.80, una sensibilidad (recall) de 0.31 y un puntaje F1 de 0.45 para la clase correspondiente a eventos con $FRP_{\text{máximo}} \geq 100MW$.

Estos resultados indican que el modelo es capaz de identificar aproximadamente un tercio de los incendios de alta intensidad, manteniendo al mismo tiempo una alta confiabilidad en las alertas emitidas. Este equilibrio entre precisión y sensibilidad resulta adecuado para un sistema predictivo orientado a la gestión del riesgo, donde la saturación de alertas puede comprometer la eficiencia operativa.

7.4 Análisis de la matriz de confusión

El análisis de la matriz de confusión evidencia que el modelo identifica correctamente una proporción relevante de incendios severos, aunque aún persiste un número significativo de eventos no detectados. Para la clase no severa, el modelo presenta una tasa muy elevada de verdaderos negativos, lo que se traduce en un bajo número de falsas alarmas.

Este comportamiento confirma que el modelo prioriza la confiabilidad de las alertas, característica deseable en escenarios donde los recursos de respuesta son limitados. Figura 1.

7.5 Interpretabilidad y estructura del patrón aprendido

El análisis de importancia de variables revela que el modelo Random Forest no basa su decisión en una única variable dominante, sino en un conjunto coherente de condiciones climáticas y energéticas.

Las variables térmicas, incluyendo la temperatura media y sus rezagos temporales, concentran una fracción relevante de la importancia total, lo que sugiere que la persistencia de condiciones cálidas desempeña un rol central en la ocurrencia de incendios severos. La humedad relativa, tanto actual como rezagada, constituye el segundo grupo más influyente, reflejando el efecto progresivo de secado del combustible vegetal.

El FRP inicial actúa como una variable ancla energética, condicionando la capacidad del incendio para escalar hacia niveles de alta intensidad, mientras que el viento presenta una importancia intermedia, coherente con su rol modulador de la propagación. La precipitación muestra un impacto menor, consistente con su carácter episódico y su menor peso relativo frente a las variables térmicas e higrométricas. Figura 2.

7.6 Ajuste de hiperparámetros y priorización de la detección temprana

Con el objetivo de maximizar la capacidad del modelo para detectar incendios de alta intensidad energética ($FRP \geq 100MW$), se exploró una configuración alternativa del algoritmo Random

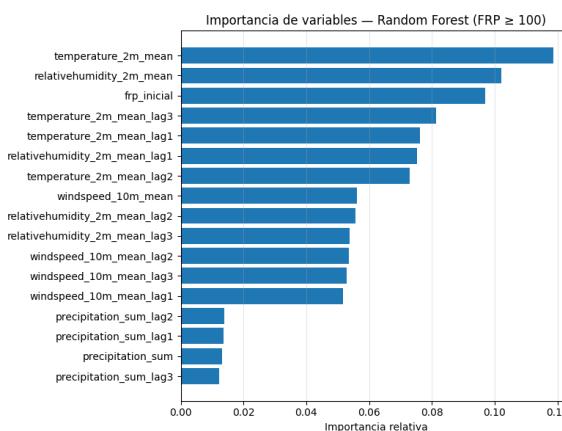


Figure 2. Importancia relativa de las variables según Random Forest

Forest orientada explícitamente a priorizar la sensibilidad (recall) de la clase severa, aun a costa de una reducción en la precisión global.

La configuración adoptada fue la siguiente:

1. **n_estimators = 800**: un número elevado de árboles permite reducir la varianza del modelo y estabilizar las predicciones en un contexto altamente ruidoso.
2. **max_depth = 15**: una profundidad intermedia limita el sobreajuste, manteniendo la capacidad del modelo para capturar interacciones no lineales relevantes.
3. **min_samples_leaf = 30**: este valor fuerza a que cada hoja represente un número suficiente de observaciones, favoreciendo patrones más generales y evitando decisiones basadas en casos extremos aislados.
4. **max_features = 0.4**: restringe el número de variables evaluadas en cada partición, aumentando la diversidad entre árboles y favoreciendo la detección de combinaciones alternativas de condiciones climáticas.
5. **class_weight = "balanced_subsample"**: ajusta dinámicamente los pesos de las clases en cada subconjunto de entrenamiento, reforzando la penalización asociada a la omisión de incendios severos.
6. **n_jobs = -1 y random_state = 42**: utilizados para optimizar el tiempo de cómputo y asegurar la reproducibilidad de los resultados.

Bajo esta configuración, el modelo alcanzó una sensibilidad (recall) de 0.92 para la clase de incendios intensos, identificando correctamente la gran mayoría de los eventos con $FRP \geq 100MW$. Este resultado confirma que el modelo puede configurarse como un sistema de alerta temprana altamente sensible, capaz de minimizar la omisión de eventos críticos.

No obstante, este incremento sustantivo en la sensibilidad se acompaña de una disminución marcada en la precisión (0.17), reflejada en un aumento significativo de falsas alarmas. La matriz de clasificación muestra que, si bien casi todos los incendios severos son detectados, una fracción considerable de eventos no severos es clasificada erróneamente como intensa. Figura 3.

Desde una perspectiva operativa, esta configuración representa un escenario extremo de priorización del riesgo, adecuado para contextos en los que el costo de no detectar un incendio severo es sustancialmente mayor que el costo de atender alertas incorrectas. En contraste, para escenarios de gestión de recursos más restrictivos, esta parametrización podría resultar inviable debido a la saturación del sistema de respuesta.

En consecuencia, los resultados evidencian que el desempeño del modelo Random Forest puede ajustarse a lo largo de un continuo entre alta sensibilidad y alta precisión, mediante la selección cuidadosa de hiperparámetros y umbrales de decisión. Este comportamiento refuerza la utilidad del enfoque propuesto como una herramienta flexible, adaptable a distintos objetivos de gestión del riesgo de incendios forestales.

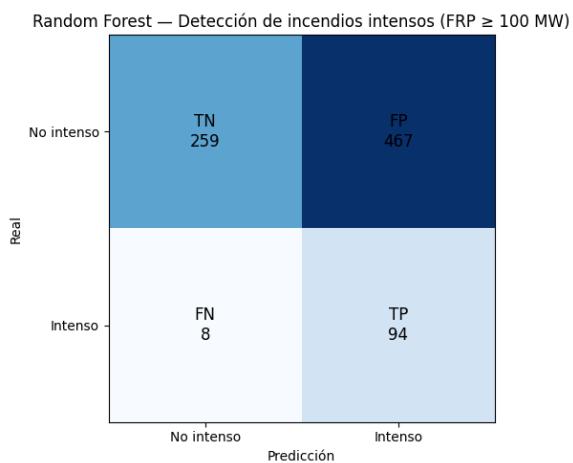


Figure 3. Desempeño del modelo Random Forest tras ajustar hiperparámetros y priorización de la detección temprana.

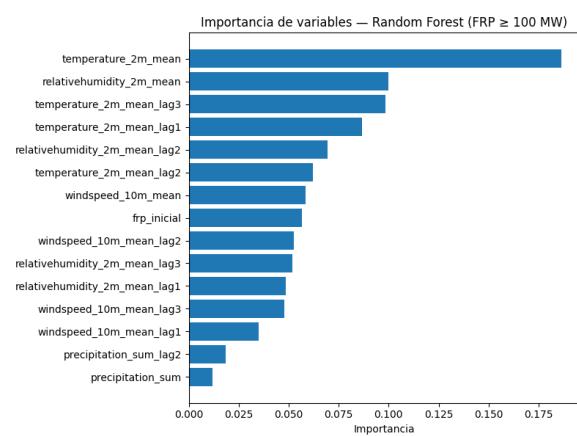


Figure 4. Desempeño del modelo Random Forest tras ajustar hiperparámetros y priorización de la detección temprana.

8 RESULTADOS

8.1 Importancia de variables predictoras

La Figura correspondiente a la importancia de variables del modelo Random Forest para la clasificación de incendios con $RP \geq 100MW$ evidencia que la predicción de eventos severos está dominada por un conjunto coherente de variables térmicas e higrométricas, junto con el estado energético inicial del incendio. Figura 2 y Figura 4

La temperatura media a 2 m se posiciona consistentemente como la variable de mayor importancia relativa, confirmando su rol central en la intensificación del fuego. Este resultado es reforzado por la alta relevancia de sus rezagos temporales (lags de 1 a 3 días), lo que indica que no solo las condiciones térmicas instantáneas, sino también la persistencia de episodios cálidos previos, favorecen la ocurrencia de incendios de alta intensidad.

En segundo lugar, la humedad relativa media a 2 m, tanto actual como rezagada, presenta una contribución significativa al modelo. La presencia de múltiples lags de humedad entre las variables más influyentes sugiere un proceso progresivo de secado del combustible vegetal, consistente con la noción de memoria climática planteada en este estudio.

El FRP inicial aparece como una variable de importancia intermedia-alta, actuando como un ancla energética que condiciona la capacidad del incendio para escalar hacia niveles críticos de intensidad. Este resultado indica que el estado inicial del fuego es relevante, pero solo adquiere un rol determinante cuando interactúa con condiciones ambientales favorables.

Las variables asociadas a la velocidad del viento muestran una importancia moderada y distribuida entre el valor instantáneo y sus rezagos temporales. Este patrón es coherente con el rol del viento como modulador de la propagación del fuego, más que como factor detonante primario de la intensidad.

Finalmente, las variables de precipitación acumulada presentan una contribución marginal al modelo, reflejando su carácter episódico y su menor influencia relativa frente a las condiciones térmicas e higrométricas persistentes.

8.2 ICoherncia entre configuraciones del modelo

El análisis comparativo de la importancia de variables bajo distintas configuraciones del modelo Random Forest muestra una estructura jerárquica estable, en la cual las variables térmicas y de humedad mantienen su predominio relativo. Si bien el peso exacto de algunas variables varía entre configuraciones, el patrón general permanece consistente, lo que refuerza la robustez de los resultados y reduce la probabilidad de que las conclusiones dependan de una parametrización específica.

Esta estabilidad sugiere que el modelo está capturando relaciones estructurales del fenómeno físico subyacente, más que asociaciones espurias inducidas por el ajuste de hiperparámetros.

8.3 Síntesis de resultados

EEEn conjunto, los resultados obtenidos indican que los incendios forestales que alcanzan una FRP máxima 100 MW se caracterizan por una combinación de alta carga térmica persistente, baja humedad relativa acumulada, un estado energético inicial no despreciable y condiciones de viento que facilitan la propagación del fuego.

La estructura de importancia de variables respalda la hipótesis central del estudio y proporciona evidencia empírica de que la intensidad extrema de los incendios en la región del Biobío responde a procesos acumulativos, más que a condiciones meteorológicas instantáneas aisladas.

9 DISCUSIÓN

9.1 Interpretación física de los patrones aprendidos por el modelo

Los resultados obtenidos confirman que la ocurrencia de incendios forestales de alta intensidad energética ($FRP \geq 100MW$) en la región del Biobío no responde a un único factor detonante, sino a la interacción coherente de múltiples variables climáticas y energéticas. En particular, la dominancia de la temperatura media y sus rezagos temporales sugiere que la intensidad extrema del fuego está fuertemente condicionada por procesos acumulativos de calentamiento y desecación del combustible vegetal.

Este patrón es consistente con la noción de memoria climática, según la cual las condiciones atmosféricas de los días previos influyen de manera decisiva en el estado hídrico del combustible fino muerto. La relevancia simultánea de la humedad relativa actual y rezagada refuerza esta interpretación, indicando que el secado progresivo del combustible es un proceso gradual, más que una respuesta instantánea a condiciones meteorológicas extremas aisladas.

9.2 Rol del estado energético inicial y variables moduladoras

El FRP inicial emerge como una variable de importancia intermedia, actuando como un ancla energética que condiciona la capacidad del incendio para escalar hacia niveles críticos de intensidad. Este resultado sugiere que, si bien un incendio puede iniciarse bajo condiciones favorables, la probabilidad de alcanzar un comportamiento extremo aumenta significativamente cuando el fuego parte desde un estado energético no despreciable.

Por su parte, la velocidad del viento presenta un rol modulador, coherente con su influencia conocida sobre la propagación del fuego y la inclinación de las llamas, más que sobre la ignición o la generación inicial de energía. La distribución relativamente homogénea de la importancia del viento entre valores actuales y rezagados sugiere que su efecto opera tanto de manera instantánea como acumulativa.

La precipitación, en contraste, muestra una contribución marginal al modelo. Este resultado no implica que la lluvia sea irrelevante en la dinámica del fuego, sino que su señal resulta débil en el contexto analizado, probablemente debido a su carácter episódico y a la predominancia de condiciones secas persistentes durante la temporada de incendios.

9.3 Implicancias del ajuste del modelo y trade-off operativo

El análisis de configuraciones alternativas del modelo Random Forest pone de manifiesto un trade-off explícito entre sensibilidad y precisión. Configuraciones orientadas a maximizar el recall permiten detectar la gran mayoría de los incendios severos, pero a costa de un incremento significativo en la tasa de falsas alarmas. En contraste, configuraciones más conservadoras priorizan la confiabilidad de las alertas, sacrificando parte de la capacidad de detección.

Este comportamiento no debe interpretarse como una limitación del enfoque, sino como una característica inherente a los sistemas de alerta temprana. La posibilidad de desplazar el modelo a lo largo de este continuo permite adaptar su uso a distintos escenarios operativos, desde contextos de vigilancia extrema —donde la omisión de eventos críticos resulta inaceptable— hasta escenarios de gestión de recursos con restricciones logísticas significativas.

9.4 Comparación con la literatura y aporte del estudio

Los resultados de este estudio son consistentes con investigaciones previas que destacan la importancia de variables térmicas e higrométricas rezagadas en la predicción del comportamiento del fuego. Sin embargo, el presente trabajo extiende estos enfoques al centrarse explícitamente en la detección de eventos de alta intensidad energética, definidos a partir de un umbral absoluto de FRP, más directamente vinculado a la gestión del riesgo.

El uso de un enfoque basado en eventos reconstruidos, junto con la incorporación sistemática de variables climáticas rezagadas, permite capturar patrones que suelen quedar fuera de análisis basados exclusivamente en condiciones instantáneas o en métricas globales de ajuste. En este sentido, el modelo Random Forest actúa no solo como un clasificador eficaz, sino también como una herramienta exploratoria que revela estructuras físicas plausibles en la dinámica de los incendios forestales.

9.5 Limitaciones y líneas futuras de investigación

A pesar de los resultados obtenidos, este estudio presenta limitaciones que deben ser consideradas. En primer lugar, el uso de variables climáticas a escala regional puede no capturar completamente la heterogeneidad local asociada a topografía, tipo de vegetación y carga de combustible. Asimismo, la definición del umbral de FRP, aunque operativamente relevante, representa una simplificación de un fenómeno continuo.

Futuras investigaciones podrían incorporar variables adicionales relacionadas con el estado de la vegetación, tales como índices de verdor (NDVI) o estimaciones de contenido de humedad del combustible vivo, así como información topográfica detallada. Asimismo, la exploración de modelos híbridos o enfoques probabilísticos podría contribuir a mejorar la cuantificación de la incertidumbre asociada a las predicciones.

En conjunto, los resultados presentados refuerzan la utilidad de integrar memoria climática y aprendizaje automático no lineal para avanzar en la comprensión y predicción de incendios forestales de alta intensidad en la región del Biobío.

10 CONCLUSIONES

Este estudio demostró que es posible anticipar la ocurrencia de incendios forestales de alta intensidad energética ($FRP \geq 100MW$) en la región del Biobío mediante el uso de técnicas de

aprendizaje automático no lineal, integrando variables meteorológicas actuales y rezagadas junto con información energética inicial del incendio.

Los principales hallazgos pueden sintetizarse de la siguiente manera:

1. **Relevancia de la memoria climática:** La temperatura y la humedad relativa, especialmente a través de sus rezagos temporales de uno a tres días, emergen como los factores más influyentes en la predicción de incendios severos. Esto confirma que la intensidad extrema del fuego responde a procesos acumulativos de calentamiento y secado del combustible, más que a condiciones meteorológicas instantáneas aisladas.
2. **Rol del estado energético inicial:** El FRP inicial actúa como un condicionante clave en la escalabilidad del incendio, reforzando la idea de que los eventos severos surgen de la interacción entre un estado energético de partida significativo y un contexto climático favorable.
3. **Capacidad del modelo Random Forest:** El modelo Random Forest demostró ser una herramienta adecuada para capturar relaciones no lineales y patrones complejos en un fenómeno altamente ruidoso, permitiendo discriminar eventos severos con distintos niveles de sensibilidad y precisión según la configuración adoptada.
4. **Trade-off operativo explícito:** Los resultados evidencian un compromiso inevitable entre la detección temprana de incendios severos y la generación de falsas alarmas. La posibilidad de ajustar hiperparámetros y umbrales de decisión permite adaptar el modelo a distintos escenarios operativos, desde sistemas de alerta temprana altamente sensibles hasta esquemas de gestión de recursos más conservadores.

En conjunto, estos resultados refuerzan la utilidad de integrar enfoques de aprendizaje automático no lineal y memoria climática para mejorar la anticipación de incendios forestales de alta intensidad energética en la región del Biobío. Más allá de su valor predictivo, el enfoque propuesto contribuye a una mejor comprensión de los procesos físicos que gobiernan la intensificación del fuego, ofreciendo una base metodológica sólida para el desarrollo de sistemas de apoyo a la toma de decisiones en contextos de riesgo.

Para futuras investigaciones, se sugiere incorporar variables de estado de la vegetación (como NDVI o contenido de humedad del combustible vivo) y topografía local para refinar la precisión del modelo y reducir la tasa de falsos positivos.

11 REFERENCIAS

- [1] Wooster, M. J., Zhukov, B., & Oertel, D. (2003). Fire radiative energy for quantitative study of biomass burning: Derivation from the BIRD experimental satellite and comparison to MODIS fire products. *Remote Sensing of Environment*, 86(1), 83-107.
- [2] Quan, X., Wang, W., Xie, Q., He, B., de Dios, V. R., Yebra, M., & Chen, R. (2023). Improving wildfire occurrence modelling by integrating time-series features of weather and fuel moisture content. *Environmental Modelling & Software*, 170, 105840.
- [3] Cordero, R. R., Feron, S., Damiani, A., Carrasco, J., Karas, C., Wang, C., ... & Beaulieu, A. (2024). Extreme fire weather in Chile driven by climate change and El Niño–Southern Oscillation (ENSO). *Scientific reports*, 14(1), 1974.
- [4] Alizadeh, M. R., Adamowski, J., & Entekhabi, D. (2024). Land and atmosphere precursors to fuel loading, wildfire ignition and post-fire recovery. *Geophysical Research Letters*, 51(2), e2023GL105324.
- [5] Oyarzo, J. A. C. (2025). Análisis de la relación entre factores espaciales y la ignición de los incendios forestales en la Zona Centro-Sur de Chile (Doctoral dissertation, Universidad de Concepción).
- [6] RIQUELME, D. A. I. (2024). Estimación de la probabilidad de ignición de incendios forestales y su proyección en escenarios de cambio climático.
- [7] CONAF (2024). Estadísticas de ocurrencia y daño de incendios forestales. Corporación Nacional Forestal, Chile.
- [8] Li, F., Zhang, X., Kondragunta, S., & Csizar, I. (2018). Comparison of fire radiative power estimates from VIIRS and MODIS observations. *Journal of Geophysical Research: Atmospheres*, 123(9), 4545-4563.
- [9] Abatzoglou, J. T., Williams, A. P., & Barbero, R. (2019). Global emergence of anthropogenic climate change in fire weather indices. *Geophysical Research Letters*, 46(1), 326-336.

- [10] Urrutia-Jalabert, R., González, M. E., González-Reyes, Á., Lara, A., & Garreaud, R. (2018). Climate variability and forest fires in central and south-central Chile. *Ecosphere*, 9(4), e02171.
- [11] Duarte, E., Rubilar, R., Matus, F., Garrido-Ruiz, C., Merino, C., Smith-Ramirez, C., ... & Jofré, I. (2024). Drought and wildfire trends in native forests of South-Central Chile in the 21st century. *Fire*, 7(7), 230.
- [12] Ellis, T. M., Bowman, D. M., Jain, P., Flannigan, M. D., & Williamson, G. J. (2022). Global increase in wildfire risk due to climate-driven declines in fuel moisture. *Global change biology*, 28(4), 1544-1559.
- [13] Schroeder, W., Oliva, P., Giglio, L., & Csiszar, I. A. (2014)The New VIIRS 375 m active fire detection data product: Algorithm description and initial assessment. *Remote Sensing of Environment*, 143, 85-96.
- [14] Moayedi, H., & Khasmaki, M. A. S. A. (2023). Wildfire susceptibility mapping using two empowered machine learning algorithms. *Stochastic Environmental Research and Risk Assessment*, 37(1), 49-72.
- [15] Roberts, G., Wooster, M. J., Perry, G. L., Drake, N., Rebelo, L. M., Dipotso, F. (2005). Retrieval of biomass combustion rates and totals from fire radiative power observations: Application to southern Africa using geostationary SEVIRI imagery. *Journal of Geophysical Research: Atmospheres*, 110(D21).
- [16] Westerling AL, HG Hidalgo, DR Cayan, TW Swetnam. 2006. Warming and earlier spring increase western U.S. forest wildfire activity. *Science* 313(5789): 940-943
- [17] Jolly, W. M., Cochrane, M. A., Freeborn, P. H., Holden, Z. A., Brown, T. J., Williamson, G. J., Bowman, D. M. (2015). Climate-induced variations in global wildfire danger from 1979 to 2013. *Nature communications*, 6(1), 7537.
- [18] Verma, A., & Dong, X. (2016). Detection of ventricular fibrillation using random forest classifier. *Journal of Biomedical Science and Engineering*, 9(05), 259.
- [19] Cutler, D. R., Edwards Jr, T. C., Beard, K. H., Cutler, A., Hess, K. T., Gibson, J., & Lawler, J. J. (2007). Random forests for classification in ecology. *Ecology*, 88(11), 2783-2792.
- [20] Molnar, C. (2020). Interpretable machine learning. Lulu. com.